

Roteiro

Processos Estocásticos – Trabalho computacional 1

- 1.1 – Leia as imagens que você recebeu.
- 1.2 – Visualize no monitor de vídeo as imagens lidas.
- 1.3 – Converta as imagens para o formato em níveis de cinza (*gray-level*).
- 1.4 – Visualize e imprima as imagens em níveis de cinza.
- 1.5 – Requantize as imagens para 4 bits. Observe o que acontece. Discuta os resultados.
- 1.6 – Requantize as imagens para 2 e 1 bit. Observe e discuta os resultados.
- 1.7 – Construa um histograma das imagens que você recebeu. Plote as curvas.
- 1.8 – Normalize cada histograma pela respectiva “área” ocupada. Plote as curvas.

Processos Estocásticos – Trabalho computacional 2

- 2.1 – Observe que o histograma normalizado corresponde a PMF para cada imagem recebida. Compute a expectância, a moda e a mediana. Calcule a média aritmética de sua PMF e compare com a média estatística calculada.
- 2.2 – Calcule os momentos de segunda e de terceira ordem para cada PMF.
- 2.3 – Calcule os momentos centrais de segunda e de terceira ordem para cada PMF.
- 2.4 – Calcule o “skewness” e a “kurtosis” para cada PMF
- 2.5 – Observe os resultados obtidos nos itens 2.1 a 2.3. Construa uma tabela. Compare e discuta os resultados.
- 2.6 – Compute a entropia de Shannon, definida como:

$$\mathcal{E} = - \sum_{k=0}^{N-1} p(x_k) \log_2 \{p(x_k)\} \quad (1)$$

- 2.7 – Essas grandezas calculadas no Trabalho computacional 2 podem ser utilizadas como grandezas randômicas. Explique. Elas são grandezas contáveis ou não contáveis?

Processos Estocásticos – Trabalho computacional 3

3.1 – Leia o banco de imagens dado.

3.2 – Calcule as grandezas estatísticas para cada uma das imagens.

3.3 – Escreva essas grandezas numéricas calculadas para cada imagem como uma linha de um arquivo CSV.

Construa dois bancos de dados como mostrado a seguir.

Para cada imagem construir uma instância do seu banco de dados, na seguinte forma:

Caso 1: utilizar o histograma calculado usando 8 *bins*.

$h[0], h[1], \dots, h[7], 0 \rightarrow$ na última coluna um identificador do tipo de imagem.

Caso 2: utilizar o histograma calculado usando 16 *bins*.

Caso 3: utilizar o histograma calculado usando 32 *bins*.

3.4 – Adicione um rótulo na última coluna do arquivo CSV identificando o tipo de imagem.

0 – Alzheimer

1 – COVID

2 – Brazilian seeds

3 – Brazilian leaves

4 – skin_cancer

Processos Estocásticos – Trabalho computacional 4

4.1 – Leia o banco de imagens dado.

4.2 – Calcule as grandezas estatísticas para cada uma das imagens.

4.3 – Escreva essas grandezas numéricas calculadas para cada imagem como uma linha de um arquivo CSV.

Construa dois bancos de dados como mostrado a seguir.

Caso 1: Utilizar as outras grandezas na sequência mostrada a seguir

expectância, moda, mediana, *squared range*, variância, *skewness*, *kurtosis*, entropia, 0

4.4 – Adicione um rótulo na última coluna do arquivo CSV identificando o tipo de imagem.

0 – Alzheimer

1 – COVID

2 – Brazilian seeds

3 – Brazilian leaves

4 – skin_cancer

Processos Estocásticos – Trabalho computacional 5

4.1 – Construa classificadores usando a Lei da Bayes, discriminante quadrático e discriminante linear. Use o banco de imagens recebido separando 90% do total de imagens para fazer o treinamento e 10% para testar o desempenho da sua ferramenta.

4.2 – Em cenários com mais de duas classes, a matriz de confusão é comumente usada para a avaliação de desempenho. A diagonal principal da matriz de confusão indica a razão entre a taxa de verdadeiros positivos de uma classe para o total de instâncias da respectiva classe. Neste caso esta grandeza pode ser tomada como uma medida de acuraria para cada classe a ser identificada.

$$P_r[k] = \frac{T_p[k]}{P[k]} \quad (2)$$

A acurácia é calculada pela média ponderada da taxa de verdadeiros positivos de cada classe.

$$A_c = \frac{\sum_{k=1}^N T_p[k]}{\sum_{k=1}^N P[k]} \quad (3)$$

Construa a matriz de confusão do seu experimento e calcule a acurácia das técnicas implementadas. Avalie e comente os resultados.

Processos Estocásticos – Trabalho computacional 6

5.1 – Observe o conjunto de funções que está no arquivo Python chamado “FIRST_ORDER_STATISTICS_Dec_18th_2024.py”. Dê uma olhada no conjunto de funções. Você consegue discernir o objetivo delas em acordo com o que foi estudado em nosso curso. Algumas coisas não fazem parte do assunto estudado, mas não assusta.

Exemplo: como obter a CDF inversa:

```
#-----  
#  
# Calculate the value of the variable according to P(X < x)  
# FAON - Jan 15th, 2023.  
#  
#-----  
def Compute_inverse_cdf(cdf, probability):  
    N = cdf.shape[0]  
    for k in range(N):
```

```
if(cdf[k] > probability):  
    return k
```

5.2 – Use o conjunto de funções de “FIRST_ORDER_STATISTICS_Dec_18th_2024.py” para computar a “features” para o conjunto de imagens recebidas. Avalie novamente o desempenho para as três técnicas desenvolvidas: Naïve Bayes, discriminante quadrático e discriminante linear.

5.3 – Observe o banco de imagens de radiografia torácica que está na pasta “Dataset_COVID_Normal”. Aplique o extrator de *features* (FIRST_ORDER_STATISTICS_Dec_18th_2024.py) para cada conjunto de imagens. Separe 80% para treinamento e 20% para teste. Avalie o desempenho quanto a capacidade de discriminação de cada conjunto de imagens do banco de dados para as três técnicas implementadas: Naïve Bayes, discriminante quadrático e discriminante linear.

Processos Estocásticos – Trabalho computacional 7

6.1 – Considere o arquivo “Breast_Cancer_data_Suwal_2018.csv”. Esse arquivo contém um conjunto de *features* condicionados a uma determinada classe discriminativa. Aplique os três algoritmos desenvolvidos aos arquivo CSV recebido. Escolha uma quantidade para treino e outra para teste. Avalie o desempenho dos seus algoritmos quanto ao banco de dados utilizados.

6.2 – Faça uma avaliação comparativa entre os três classificadores. Simule 10 vezes. Tome a média aritmética como o valor esperado de cada classificador. Coloque os resultados em tabelas.

6.3 – Qual é o classificador que apresenta melhor desempenho? Existe alguma justificativa plausível?

6.4 – Tente calcular um intervalo de confiança para o valor esperado da acurácia. Utilize níveis de confiança 95% e 99.7%. Considere que o problema tem distribuição de probabilidade Gaussiana. Avalie e critique os resultados.

Processos Estocásticos – Trabalho computacional 8

7.1 Idêntico ao Trabalho 7, só que agora você deve usar o arquivo “data_Lung_Cancer.csv”.

Processos Estocásticos – Trabalho computacional 9

8.1 Idêntico ao Trabalho 7, só que agora você deve usar o arquivo “*data_Mammography.csv*”.

Processos Estocásticos – Trabalho computacional 10

10.1 Idêntico ao Trabalho 7, só que agora você deve usar o arquivo “*Data_Alzheimer_Diagnosis.csv*”.

Processos Estocásticos – Trabalho computacional 11

11.1 Idêntico ao Trabalho 7, só que agora você deve usar o arquivo “*smart_grid_stability_augmented_ML.csv*”.

Processos Estocásticos – Trabalho computacional 12

12.1 Idêntico ao Trabalho 6, só que agora você deve usar o arquivo “*DataSet_folhas_celular.csv*”.

Atenciosamente,



Francisco Assis de Oliveira Nascimento, Ph.D.
Professor Titular
Coordenador do Grupo de Pesquisa em Processamento Digital de Sinais
Departamento de Engenharia Elétrica
Faculdade de Tecnologia
Universidade de Brasília - UnB